NLP-Disaster-Tweets-Classification

INTEGRANTES
Assandry Barón Rodríguez - assandry.baron@udea.edu.co

TUTOR
Raul Ramos Pollan - raul.ramos@udea.edu.co
Julian David Arias Londoño - julian.ariasl@udea.edu.co

Fundamentos de Deep Learning

Universidad de Antioquia
Facultad de Ingeniería
Ingeniería de Sistemas
Medellín, Antioquia, Colombia
2026

1. Contexto de Aplicación

En situaciones de crisis y desastres naturales, la rapidez en la identificación de información crítica puede salvar vidas. Las redes sociales, específicamente Twitter, funcionan como un sistema de alerta temprana; sin embargo, el volumen de datos y el uso de lenguaje figurado generan "ruido" que dificulta la labor de los servicios de emergencia. Este proyecto busca automatizar la distinción entre avisos de desastres reales y comentarios irrelevantes utilizando Procesamiento de Lenguaje Natural (NLP).

2. Objetivo de Machine Learning

El objetivo técnico es desarrollar un modelo de clasificación binaria basado en Redes Neuronales Recurrentes (RNN). El sistema procesará secuencias de texto (X) para predecir una etiqueta lógica (y), donde (1) representa un evento de desastre confirmado y (0) un mensaje que no requiere atención de emergencia. Se enfocarán los esfuerzos en el manejo de dependencias temporales del lenguaje.

3. Descripción del Dataset

- Fuente: Kaggle - Natural Language Processing with Disaster Tweets.
- Estado de Disponibilidad: Se ha verificado la integridad de los datos mediante descarga directa. El dataset consta de archivos en formato CSV (sample_submission.csv, train.csv y test.csv).
- Estructura: El conjunto de entrenamiento incluye aproximadamente 7,600 registros con columnas de texto crudo, palabras clave (keywords) y localización geográfica.
- Calidad de datos: Los datos son ligeros (menos de 1 MB), lo que permite una manipulación ágil sin restricciones de memoria local.

4. Métricas de Desempeño

- Métrica Principal: Se utilizará el F1-Score. Dado que en problemas de emergencia es tan grave omitir un desastre real (Falso Negativo) como dar una falsa alarma (Falso Positivo), esta métrica es la más robusta para evaluar el equilibrio del modelo.
- Función de Pérdida: Se implementará Binary Cross-Entropy, adecuada para la naturaleza binaria de la salida del modelo.

5. Requerimientos y Primera Iteración

- Estimación Computacional: El proyecto se desarrollará en Google Colab utilizando aceleración por GPU para optimizar el entrenamiento de las capas recurrentes.
- Alcance Inicial: Siguiendo las recomendaciones, la primera iteración consistirá en un pipeline básico de limpieza de texto (remoción de URLs y puntuación), tokenización y una arquitectura simple de LSTM. El objetivo es validar la capacidad del modelo para generar predicciones coherentes antes de avanzar hacia arquitecturas más complejas como capas de Attention o Transfer Learning con BERT.